



Universidad de Buenos Aires
Facultad de Ciencias Económicas

Universidad de Buenos Aires.
Facultad de Ciencias Económicas
Escuela de Estudios de Posgrado.

MAESTRÍA EN ECONOMÍA APLICADA

Taller de Programación

TERCER TRABAJO PRÁCTICO

CLASIFICANDO DE POBRES CON LA EPH

AUTORES:

KOSTZER FEDERICO

MEZA PALMA MANUEL H.

PARDINI MAXIMILIANO G.

DOCENTE: ROMERO MARIA NOELIA

NOVIEMBRE 2025

A. Enfoque de validación.

Se utilizó la base *respondieron* para la construcción de los conjuntos de entrenamiento y testeo. Para cada año, las observaciones se dividieron en una muestra de entrenamiento (70%) y una de test (30%), empleando `random_state = 444` para asegurar la reproducibilidad de los resultados. La variable dependiente fue *pobre*, definida como un indicador binario que toma valor 1 si el ITF del hogar es inferior al ingreso necesario y 0 en caso contrario. La matriz de predictores incluyó únicamente variables disponibles también en la base *norendieron*, incorporando además una columna de unos para el intercepto.

1. Selección de variables y diferencia de medias

La selección de variables incluyó únicamente aquellas previamente limpiadas en trabajos prácticos anteriores, manteniendo dos criterios centrales: baja proporción de valores faltantes y relevancia conceptual para predecir la pobreza. Se excluyeron variables con pérdida excesiva de casos (*cat_inac*, *cat_ocup*, *aglomerado*), con el objetivo de preservar el tamaño muestral y evitar problemas derivados de imputaciones masivas. Para las variables retenidas, los valores faltantes se imputaron mediante la mediana, garantizando estabilidad sin introducir supuestos fuertes sobre la distribución.

Las variables seleccionadas fueron las siguientes:

- **ch04 (sexo):** incorporada por las diferencias de inserción laboral e ingresos entre varones y mujeres, que pueden afectar directamente la probabilidad de pobreza.
- **ch06 (edad):** permite capturar heterogeneidades en capacidad de generar ingresos y en dependencia económica, especialmente en niños y adultos mayores.
- **ch07 (estado civil):** vinculado a la estructura familiar y a la distribución de responsabilidades económicas dentro del hogar.
- **ch09 (alfabetización):** proxy básico del capital humano, asociado a empleabilidad e ingresos potenciales.
- **ch10 (asistencia o historial educativo):** aproxima trayectorias educativas relevantes para explicar oportunidades económicas futuras.
- **nivel_ed (nivel educativo alcanzado):** factor estrechamente asociado con el retorno salarial y la estabilidad laboral.
- **estado (condición de actividad):** determinante directo del bienestar, al ser el empleo el principal canal de acceso a ingresos.
- **ch03 (relación de parentesco):** permite identificar la posición del individuo dentro del hogar y las relaciones de dependencia económica.
- **pp3e_tot_clean (horas trabajadas):** indicador de intensidad laboral. Su versión depurada se obtuvo reemplazando los valores mayores al percentil 99 por valores faltantes, evitando la influencia de outliers no plausibles sin distorsionar la distribución general.

Estas variables permiten capturar de manera integrada la heterogeneidad demográfica, educativa, laboral y familiar que determina el riesgo de pobreza. Constituyen además un conjunto consistente con los determinantes clásicos de la literatura económica, garantizando que los modelos estimados sobre la base *respondieron* mantengan capacidad predictiva al ser aplicados posteriormente a la base *norendieron*.

Se construyó una tabla comparando las medias de cada predictor en las muestras de entrenamiento y test. Los resultados muestran diferencias mínimas entre ambos subconjuntos, sin indicios de desbalances sistemáticos. Ello confirma que la partición aleatoria preservó la representatividad de la base original y que no existen sesgos relevantes que afecten la validez del proceso de entrenamiento.

Tabla 1. Estadísticos descriptivos de predictores seleccionados

Variable	Media Train	Media Test	Dif	Abs_Dif
pp3e_tot_clean	13.955	13.696	0.259	0.259
edad	34.124	33.961	0.162	0.162
estado	2.296	2.311	-0.015	0.015
ch04_2	0.520	0.527	-0.007	0.007
ch10	1.720	1.713	0.007	0.007
ch07	3.575	3.580	-0.005	0.005
nivel_ed_3	0.191	0.194	-0.003	0.003
nivel_ed_6	0.108	0.105	0.003	0.003
nivel_ed_4	0.172	0.169	0.003	0.003
nivel_ed_5	0.115	0.113	0.002	0.002
nivel_ed_2	0.153	0.154	-0.002	0.002
nivel_ed_7	0.086	0.087	-0.001	0.001
ch09	1.119	1.119	-0.000	0.000
intercepto	1	1	0	0

En síntesis, la comparación de medias indica que las muestras de entrenamiento y testeo se encuentran adecuadamente balanceadas, lo que permite avanzar de manera robusta hacia la etapa de estimación y validación de modelos predictivos.

2. División por año

Se procedió a dividir las bases *respondieron* y *norespondieron* según el año de relevamiento, generándose cuatro subconjuntos: *respondieron_2005*, *respondieron_2025*, *norespondieron_2005* y *norespondieron_2025*.

En la base *respondieron* se obtuvieron 46.592 observaciones correspondientes a 2005 y 33.372 observaciones correspondientes a 2025, totalizando 79.964 registros. En la base

norespondieron, el total asciende a 12.491 observaciones, de las cuales 438 pertenecen a 2005 y 12.053 al año 2025.

La diferencia en magnitud entre los dos períodos refleja tanto la expansión del operativo estadístico en años recientes como un posible aumento de la tasa de no respuesta. Esta segmentación temporal permite analizar la comparabilidad de los perfiles entre encuestados y no encuestados en ambos años, así como evaluar la estabilidad de las variables seleccionadas para los modelos predictivos que se estimarán posteriormente.

B. Modelo de regresión logística.

Se estimó un modelo de regresión logística utilizando la base **respondieron_2025**, con *pobre* como variable dependiente y las variables previamente seleccionadas como predictores. El modelo fue ajustado mediante máxima verosimilitud y alcanzó convergencia satisfactoria. La **Tabla 2** presenta los coeficientes estimados, los errores estándar y los odds ratios correspondientes.

Los resultados muestran que **todas las variables son estadísticamente significativas al 1%**, con excepción del intercepto. Las señales de los coeficientes son coherentes con la teoría económica y con la evidencia previa sobre determinantes de la pobreza.

En primer lugar, la edad (ch06) presenta un coeficiente negativo, lo que indica que a mayor edad disminuye la probabilidad de ser pobre. Esto puede asociarse a una mayor estabilidad ocupacional, trayectoria laboral acumulada o mayores retornos a la experiencia. En la misma dirección, las horas trabajadas (pp3e_tot_clean) muestran un efecto negativo y significativo, reflejando que una mayor inserción laboral reduce el riesgo de pobreza.

El nivel educativo (nivel_ed) constituye uno de los predictores más relevantes: su coeficiente negativo y un odds ratio de 0.75 muestran que un incremento en el nivel educativo reduce sustancialmente la probabilidad de ser pobre, en línea con la estrecha relación entre educación, empleabilidad y retorno salarial.

Por el contrario, la condición de actividad (estado) exhibe un coeficiente positivo, lo que implica que las categorías asociadas a inactividad o desocupación aumentan significativamente el riesgo de pobreza. Asimismo, variables vinculadas a alfabetización o trayectoria educativa (ch09 y ch10) presentan coeficientes positivos, lo que sugiere que ciertos grupos con recorridos educativos más débiles o vulnerables enfrentan un riesgo mayor.

La variable sexo (ch04) también presenta un coeficiente positivo, indicando que uno de los grupos experimenta una probabilidad mayor de ser pobre—aunque esto requeriría un análisis adicional sobre brechas de género en ingresos y participación laboral. Por último, la relación de parentesco (ch03) señala que individuos que no ocupan el rol de jefe de hogar presentan una mayor probabilidad de pobreza.

En conjunto, el modelo presenta un **pseudo R² de 0.0806**, un valor consistente con la literatura aplicada a modelos de pobreza a nivel individual. Los resultados permiten identificar factores relevantes asociados al riesgo de pobreza en 2025 y constituyen una base útil para la construcción de modelos predictivos.


Medidas del modelo:

- **N = 23.360**
- **Log-Likelihood = -14.824**
- **Pseudo R² = 0.08063**
- **LLR p-value = 0.000**

Tabla 2. Resultados modelo de regresión logística

Variable	Coefficiente	Error estándar	Odds Ratio
const	0.0690	0.1113	1.0714
ch04	0.1776	0.0288	1.1944
ch06	-0.0225	0.0009	0.9777
ch07	-0.0588	0.0105	0.9429
pp3e_tot_clean	-0.0050	0.0012	0.9950
nivel_ed	-0.2840	0.0095	0.7528
estado	0.2140	0.0165	1.2387
ch03	0.0639	0.0102	1.0660
ch09	0.2867	0.0568	1.3320
ch10	0.4788	0.0415	1.6141

Probabilidad estimada de pobreza según la edad.



El gráfico muestra una relación no lineal entre la edad y la probabilidad de ser pobre. En las edades más tempranas —entre 1 y 10 años— la probabilidad estimada es elevada, ubicándose entre 0.68 y 0.78, lo cual es esperable dado que los menores dependen completamente del nivel socioeconómico del hogar y no participan del mercado laboral.

A medida que aumenta la edad hacia la adultez joven y media, la probabilidad de pobreza tiende a disminuir, reflejando la incorporación al mercado de trabajo y el incremento progresivo del ingreso laboral. Esto se corresponde con un patrón típico donde el riesgo de pobreza se reduce en las edades económicamente activas.

Sin embargo, a edades muy avanzadas la probabilidad podría volver a incrementarse —algo habitual en poblaciones donde las jubilaciones son insuficientes—, aunque este comportamiento debe interpretarse con cautela debido a la menor cantidad de observaciones en edades extremas.

En síntesis, el gráfico evidencia que la edad es un determinante significativo del riesgo de pobreza, con altas probabilidades en la niñez, una caída durante la adultez y posibles incrementos hacia edades avanzadas. Esta dinámica respalda la inclusión de la variable *ch06* en el modelo predictivo.

C. Método de vecinos cercanos (KNN)

Al realizar el entrenamiento de nuestro modelo con un número de vecinos $K=\{1,5,10\}$ se determinó el número óptimo de vecinos con $k = 10$ dando este un *accuracy* de 0.64; se pasó a reentrenar el modelo con este hiperparámetro arrojándose una cantidad de 1543 falsos positivos y 2059 falsos negativos ambos resultados menores que los verdaderos positivos y verdaderos negativos computados en 2488 y 3922 respectivamente, como se muestra en la tabla 3. En términos de políticas públicas los falsos positivos estarían desviando recursos hacia personas que no los necesitan, por su parte los falsos negativos son un número elevado de personas que deben ser alcanzadas por los programas de combate de la pobreza y no se estarían beneficiando de estos.


Tabla 3. Matriz de confusión KNN

Categorías	No pobres predichos	Pobres predichos
No pobres observados	3922	1543
Pobres observados	2059	2488

A medida que aumentamos el número de vecinos la heterogeneidad en las características crece lo que suaviza demasiado la frontera de decisión produciendo alto sesgo; por el contrario, cuando K es pequeño el modelo se ajusta demasiado a los datos produciendo alta varianza.



En la figura 2 se muestran gráficos de frontera de decisión que son un intento de demarcación entre pobres y no pobres utilizando como predictores la edad y el número total de horas trabajadas en la ocupación principal de los encuestados; dado que las observaciones se superponen en un gran cluster resulta imposible establecer una línea de clasificación exacta de los dos grupos; el número de vecinos no determina una mejora en el proceso.



Por su parte la figura 3 presenta el comportamiento del proceso de elección del k óptimo mediante cross-validation con 5 pliegues (folds); la trayectoria es creciente hasta el sexto vecino luego de lo cual comienza a oscilar estableciéndose el óptimo con una precisión promedio de 0.632 en el noveno, este resultado es ligeramente menor que en el modelo de validación simple.

D. Desempeño de modelos afuera de la muestra, métricas y políticas públicas


En este apartado compararemos el desempeño de las predicciones de pobreza en 2025 de los modelos Logit y KNN con K-CV.

Lo primero para realizarlo será observar la matriz de confusión para Logit:

4063	1402
2163	2384

En la misma podemos ver que el modelo clasifica correctamente a 4063 hogares no pobres y 2384 hogares pobres, mientras que comete 1402 falsos positivos (no pobres etiquetados como pobres) y 2163 falsos negativos (pobres clasificados como no pobres). En términos agregados, el modelo acierta alrededor del 64% de los casos, pero deja fuera a una cantidad considerable de hogares pobres.

En segundo lugar veremos las curvas ROC de ambos modelos:



El área bajo la curva (AUC) del logit es aproximadamente 0,697, mientras que la del KNN K-óptimo es 0,688. Esto indica que los dos modelos tienen una capacidad de discriminación moderada y bastante similar, con una pequeña ventaja del logit en términos de ranking de probabilidades: en promedio ordena un poco mejor a los hogares desde “más pobre” a “menos pobre”.

Por último, veremos las métricas de clasificación de ambos modelos.

	LOGIT	KNN K-CV
Accuracy	0,643	0,642
Recall	0,524	0,628

Precisión	0,629	0,601
-----------	-------	-------

El *accuracy* de ambos modelos es prácticamente idéntico (en torno al 64%), por lo que este indicador por sí solo no permite distinguirlos. Sin embargo, existen diferencias importantes en otros aspectos: el **KNN presenta una sensibilidad claramente mayor (0,63 vs 0,52)**, es decir, detecta una proporción más alta de hogares pobres, a costa de una precisión algo menor (algo más de “chorreo” hacia no pobres). El logit, en cambio, ofrece una mejor precisión y un AUC ligeramente superior, pero se le escapa una fracción más grande de hogares pobres.

Desde la perspectiva del Ministerio de Capital Humano, el objetivo central del programa de alimentos es identificar a los hogares efectivamente pobres para dirigir recursos escasos. En este contexto, los distintos tipos de error tienen implicancias muy diferentes:

Un falso negativo (pobre clasificado como no pobre) implica dejar fuera del programa a un hogar que necesita asistencia, lo que constituye un error de exclusión.

Un falso positivo (no pobre clasificado como pobre) supone asignar recursos a quienes no los necesitan, generando un uso ineficiente del presupuesto, pero con un costo social relativamente menor que el anterior.

Por lo tanto, consideramos mejor priorizar modelos que minimicen los falsos negativos, aun a costa de aceptar un número algo mayor de falsos positivos por los que nos quedamos con el KNN.

A la hora de predecir que personas son pobres dentro de la base de los que no respondieron sus ingresos en 2025, obtenemos un 73% de pobres, lo cual es un porcentaje bastante mayor a los que sí respondieron. A partir de esto podemos suponer que son las personas pobres las que prefieren no decir de cuanto son sus ingresos.