



Universidad de Buenos Aires
Facultad de Ciencias Económicas

Universidad de Buenos Aires.
Facultad de Ciencias Económicas
Escuela de Estudios de Posgrado.

MAESTRÍA EN ECONOMÍA APLICADA

Taller de Programación

CUARTO TRABAJO PRÁCTICO

CLASIFICANDO POBRES EN LA EPH: MÉTODOS DE
REGULARIZACIÓN Y CART

AUTORES:

KOSTZER FEDERICO

MEZA PALMA MANUEL H.

PARDINI MAXIMILIANO G.

DOCENTE: ROMERO MARIA NOELIA


NOVIEMBRE 2025

A. Modelo de Regresión logística con Regularización: Ridge y LASSO.

1. Visualización


Se presentan los coeficientes estimados por modelos de Regresión Logística regularizados mediante penalizaciones L1 (LASSO) y L2 (Ridge), evaluados sobre una grilla de valores de penalidad $\lambda = 10^n$ con $n \in \{-5, -4, \dots, 5\}$.

En LogisticRegression, la regularización se controla a través del parámetro $C = 1/\lambda$; por lo tanto, valores grandes de λ (equivalentes a C pequeños) implican una mayor fuerza de penalización sobre los coeficientes.



En el caso de LASSO, la figura muestra que, a medida que λ aumenta, varios coeficientes se reducen exactamente a cero. Este comportamiento evidencia el carácter espeso de la penalización L1, que funciona como un mecanismo implícito de selección de variables. Como resultado, LASSO tiende a producir modelos más simples y potencialmente más interpretables, especialmente cuando ciertos predictores aportan información limitada.

En contraste, la penalización Ridge genera una reducción más suave y continua de los coeficientes. Si bien la magnitud de los parámetros disminuye a medida que crece λ , ninguno se anula por completo. Esto refleja la naturaleza estabilizadora de la penalización L2, que controla la varianza del modelo sin eliminar predictores, lo que resulta particularmente útil cuando existen correlaciones entre las variables explicativas.




En síntesis:

- LASSO (L1): induce esparsidad y selecciona automáticamente variables, favoreciendo modelos más parsimoniosos.
- Ridge (L2): contrae los coeficientes sin anularlos, priorizando estabilidad y mitigación del sobreajuste.


2. Penalidad óptima por Cross-validation y visualización.

Para determinar la penalidad óptima de los modelos de regresión logística con regularización LASSO (L1) y Ridge (L2), se aplicó **LogisticRegressionCV** con validación cruzada de 5 pliegues, evaluando la grilla de valores de λ definida previamente. Los tres gráficos presentan visualmente cómo el error promedio y la proporción de coeficientes cero varían con λ , cumpliendo con la consigna de mostrar la distribución del error de clasificación y la selección de variables.


En el primer gráfico, **LASSO: Error promedio 5-fold CV vs λ** , el error se mantiene estable para λ pequeños y aumenta significativamente para λ grandes, reflejando subajuste. La penalidad óptima seleccionada fue $\lambda^{CV} = 10.0$, valor que minimiza el error promedio (~ 0.35).



El segundo gráfico, **LASSO: Proporción de variables ignoradas vs λ** , evidencia la capacidad de LASSO para realizar selección de variables. Para λ pequeños, la mayoría de variables se conserva; a medida que λ aumenta, el modelo elimina progresivamente las variables menos relevantes, y con λ muy grandes casi todos los coeficientes se fuerzan a cero.



En el tercer gráfico, Ridge: **Error promedio 5-fold CV vs λ** , se observa un comportamiento similar en cuanto al error, alcanzando su mínimo para $\lambda^{CV} = 10.0$. A diferencia de LASSO, Ridge reduce los coeficientes sin eliminarlos, por lo que no se aprecia selección de variables.



En resumen, tanto LASSO como Ridge alcanzan su rendimiento óptimo con $\lambda = 10.0$. LASSO permite eliminar variables menos relevantes a medida que λ aumenta, mientras que Ridge conserva todas las variables. Con $\lambda^{CV} = 10.0$, LASSO mantiene la mayoría de las variables, asegurando un balance adecuado entre capacidad predictiva y simplificación del modelo.

3. Estimación con λ^{CV} y comparación de coeficientes

Se estimaron modelos de regresión logística utilizando la base X_{train} de respondieron_2025 bajo tres configuraciones: sin penalidad, con regularización LASSO (L1) y con regularización Ridge (L2), empleando como penalidad óptima $\lambda^{CV} = 10.0$ obtenida en el ítem anterior. La tabla resultante compara los coeficientes estimados para cada variable en los tres modelos.

Tabla 1. Importancia relativa de variables en especificaciones logit

Variable	Coef_sin_penalidad	Coef_L1	Coef_L2
ch06	-0.022672	-0.022189	-0.022516
ch07	-0.065662	-0.067196	-0.065490
pp3e_tot_clean	-0.007312	-0.007493	-0.007227
estado	0.223608	0.216123	0.226528
ch03	0.055176	0.052869	0.055356

Variable	Coef_sin_penalidad	Coef_L1	Coef_L2
ch09	0.015168	0.000000	-0.013067
ch10	0.467638	0.412273	0.445610
ch04_2	0.207815	0.195754	0.202812
nivel_ed_2	0.325964	0.343394	0.365459
nivel_ed_3	0.197959	0.211780	0.232890
nivel_ed_4	-0.326418	-0.281123	-0.275695
nivel_ed_5	-0.561039	-0.532299	-0.516584
nivel_ed_6	-1.674891	-1.616107	-1.586885
nivel_ed_7	-0.759804	-0.646559	-0.661879
intercepto	-0.051575	0.000000	-0.041187

La comparación de los coeficientes estimados muestra que los modelos regularizados, tanto LASSO (L1) como Ridge (L2), presentan valores cercanos a los obtenidos en el modelo sin penalidad, lo que indica que la penalización seleccionada no altera de manera significativa la magnitud ni el signo de los efectos. Esto permite mantener una interpretación consistente de las variables relevantes.


En el caso de LASSO, se observa una reducción de algunos coeficientes, llegando incluso a forzar a cero el coeficiente de la variable *ch09* y del intercepto. Este comportamiento evidencia la capacidad de LASSO para realizar selección de variables, eliminando aquellas menos relevantes y simplificando el modelo sin comprometer su desempeño predictivo.

Por su parte, Ridge reduce la magnitud de todos los coeficientes, pero no elimina ninguna variable. Todas las características permanecen en el modelo, confirmando que la regularización L2 actúa mediante encogimiento de coeficientes sin afectar la inclusión de variables.

En definitiva, la regularización L1 permite simplificar el modelo mediante la eliminación de variables de menor relevancia, mientras que L2 actúa reduciendo la magnitud de los coeficientes sin descartar ninguna característica. En ambos casos, los coeficientes regularizados permanecen próximos a los obtenidos por el modelo sin penalización, lo que asegura la preservación de la información relevante y un equilibrio adecuado entre complejidad del modelo y capacidad predictiva.

B. Árboles de Decisión

Árbol de decisión podado




La figura muestra que, con ccp_alpha muy pequeño, el árbol casi no se poda y el error de clasificación se mantiene alto (levemente por encima de 0,39). Al aumentar ccp_alpha el error baja hasta un mínimo cercano a 0,34 alrededor de $ccp_alpha \approx 1,3 \times 10^{-4}$, que es el valor que elegimos como óptimo. A partir de ahí, si seguimos aumentando ccp_alpha , el error vuelve a crecer porque el árbol se vuelve excesivamente simple.


Visualización del árbol podado por cross-validation

En la siguiente figura mostraremos los niveles superiores del árbol CART podado con el ccp_alpha óptimo. La raíz del árbol separa a los hogares según el nivel educativo (`nivel_ed_6`), lo que indica que la educación es la primera variable que utiliza el modelo para discriminar entre pobres y no pobres. En las ramas siguientes aparecen particiones por la situación laboral (`estado`) y por características demográficas del hogar (`ch06`, `ch03`, etc.), generando grupos con distinta proporción de pobreza. En general, las ramas de la izquierda concentran hogares con mayor probabilidad de ser pobres, mientras que las de la derecha agrupan hogares predominantemente no pobres.

Además, mostraremos una figura adicional donde mostraremos la importancia de cada una de las variables para observar no solo las variables mencionadas previamente sino las que el modelo no considera relevantes.

Árbol de decisión podado (niveles superiores)





C. Comparación entre métodos

Tabla 2. Matrices de confusión de modelos especificados

En las columnas aparecen los valores predichos y en las filas los observados

Logit		Lasso		Ridge		KNN		Árbol de decisión	
3768	1697	3775	1690	3765	1700	3555	1910	3555	1910
1826	2721	1825	2722	1827	2720	1804	2743	1470	3077

En la tabla 2 se presentan las matrices de confusión de todos los modelos estimados notándose predicciones bastante cercanas de las diferentes categorías, por ejemplo para los tres modelos logit la proporción de verdaderos positivos y negativos permanece casi igual ocurriendo lo mismo para los falsos positivos y negativos; en cuanto al modelo de vecinos cercanos este se encontró más cerca de los resultados del árbol decisión sobre todo en los verdaderos negativos y falsos positivos que fueron idénticos (3555 y 1910).

De lo anterior se desprende que las métricas asociadas a cada modelo guardaran cierta similitud, para el caso todos los modelos logit obtuvieron medidas de accuracy y recall prácticamente iguales diferenciándose solo a partir de las centésimas y milésimas lo que sugiere que el sobreajuste era moderado y las respectivas penalidades no ofrecían mayores ganancias dado que se contaba con un número relativamente pequeño de predictores; en lo que se refiere a la precisión global de estos modelos clasifican correctamente alrededor del 65% de los hogares. El KNN mostro una capacidad de clasificación global más débil ubicándose su precisión en 0.63; el mejor modelo en este sentido fue el árbol de clasificación que presento una mejora modesta con respecto a los logit de alrededor del 1%.


Con el recall (sensibilidad) que es una métrica de interés en particular para el problema en cuestión ya que nos interesa capturar a los pobres reales los resultados fueron similares: los tres modelos logit no obtuvieron diferencias significativas en cuanto a esta medida detectando cerca del 60% de los pobres reales, el KNN también se ubicó en este nivel; a este respecto el mejor modelo fue el árbol de decisión aumentando su tasa de acierto en casi 8 puntos porcentuales.

Por último, se pasó a la precisión que también conviene evaluar en el problema de aplicación para ver que tan bien se filtran los verdaderos pobres del total que se obtienen como predicciones obteniéndose la respuesta más baja de parte del KNN; a su vez los modelos logit y el árbol de decisión se posicionaron con valores similares; los hallazgos anteriores pueden consultarse en la tabla 3 continuación.

Tabla 3. Métricas de desempeño modelos especificados

Modelo	Accuracy	Recall	Precision
Logit	0.6481	0.5984	0.6159
Lasso	0.6489	0.5986	0.6170
Ridge	0.6477	0.5982	0.6154
KNN	0.6290	0.6033	0.5895
Arbol de decision	0.6624	0.6767	0.6170

Como medida adicional para observar el comportamiento de los modelos se graficaron sus respectivas curvas ROC observándose el mejor desempeño del árbol de decisión con un AUC de 0.72 el mas alejado del modelo aleatorio y por tanto la mejor combinación de tasa de verdaderos positivos con tasa de falsos positivos; en segundo lugar, quedaron los modelos logit con una trayectoria idéntica en línea con lo explicado anteriormente; por ultimo entro el KNN evidenciando de nuevo su rezago en calidad predictiva.



Los modelos logit cuentan con una estructura funcional explícita lo que nos permite hacer inferencia estadística acerca de los impactos de los predictores en la variable dependiente lo que en términos de interpretabilidad es muy útil en la mayoría de contextos; cuando añadimos penalizaciones LASSO Y Ridge perdemos interpretación causal ya que los coeficientes de estos modelos no son insesgados pero son de ayuda para ver la importancia relativa de nuestros

predictores; en el ejercicio particular tenemos las tablas clásicas de regresión que permiten visualizar los respectivos impactos y la significatividad estadística a la vez que gráficos sobre el poder predictivo aportado por cada variable independiente, sin embargo sus fronteras de decisión al ser lineales solo clasifican un poco mejor que el mero azar.

El modelo de vecinos cercanos pierde interpretabilidad al no poseer una forma funcional explícita y depender de la distancia euclídea para realizar la clasificación; este tipo de modelos pueden obtener mejor desempeño que los modelos lineales si las clases a predecir muestran divisiones marcadas lo que no ocurre en el conjunto de datos por lo que las métricas empeoran comparadas con logit y árboles.

El árbol de decisión a pesar de ser un método no lineal exhibe una estructura gráfica bastante atractiva para representar las diferentes instancias de clasificación lo que lo pone en un lugar preponderante en cuanto a interpretabilidad y comunicación de resultados al público no especializado; por otra parte, fue el modelo que obtuvo mejores métricas en el conjunto de validación acentuando su elección como mejor método.

En conclusión, tenemos que el modelo más balanceado es el árbol de decisión el cual nos brinda además de un rendimiento más alto en casi todas las métricas, una presentación atractiva que permite una interpretación y comunicación más directa incluso por públicos no especializados; este sería el modelo a elegirse en el caso de la implementación de la política de alimentos a grupos vulnerables, en esto nos separamos del análisis del trabajo anterior en el que se optaba por el KNN ya que incluso en la minimización de falsos negativos el árbol resulta superior.